UNIVERSIDAD DE SAN CARLOS DE GUATEMALA

FACULTAD DE INGENIERÍA

SISTEMAS DE BASES DE DATOS 2



Kimberly Alejandra Miranda Macario	202203805
Javier Andrés Velásquez Bonilla	202307775
Katheryn Gabriela Tziná Paz	202308940

Índice

1. Introducción y alcance 3
2. Descripción de la metodología 3
2.1 Fases del proyecto 3
2.2 Tipos de carga y rondas 4
2.3 Ciclo de cada corrida 4
2.4 Herramientas 5
2.5 Registro de tiempos 6
3. Modelo entidad-relación 6
3.1 Entidades y relaciones 7
3.2 Decisiones de diseño 8
3.3 Diferencias entre el diagrama original y el DDL 9
3.4 Notas sobre los datos 10
4. Plan de respaldo 10
4.1 Estrategia 10
4.2 Scripts 10
4.3 Verificación 11
4.4 Almacenamiento persistente 11
4.5 Limitación de los respaldos incrementales 11
5. Especificaciones técnicas 11
6. Análisis detallado de resultados comparativos 12
6.1 Respaldos 13
6.2 Restauración por etapa 15
6.3 Tiempo de restauración según la longitud de la cadena 17
6.4 Peso de pg_verifybackup 18
6.5 Fragmentación 19
6.6 Validación de integridad 19
7. Justificación de conclusiones y recomendación 20
7.1 Lo medido 20
7.2 Interpretación 20
7.3 Recomendación por escenario 21
8. Alcance y limitaciones 21
Anexo A. Entregables 21
Anexo B. Comandos principales 22

1. Introducción y alcance

Este documento describe la Fase 2 del proyecto del curso Sistemas de Bases de Datos 2: el respaldo y la restauración físicos, desde consola, de la base de datos de los Juegos Olímpicos construida en la Fase 1, y el análisis comparativo de los tiempos de restauración entre el respaldo completo (FULL) y los respaldos incrementales (INCR).

El enunciado pide tres tipos de carga, por año, por deporte y por deportista, cada una en una instancia nueva de la base de datos, con un respaldo completo después de la carga base y un respaldo incremental después de cada una de las tres rondas. Después se elimina la base y se restaura el respaldo completo y cada cadena de incrementales, midiendo el tiempo y validando la integridad.

Tabla 1. Corridas analizadas

Corrida	Carga	Máquina	Evidencia
anio_pa	Por año	pa	05_logs/anio_pa/ y 05_logs/tiempos_anio_pa.csv
deporte_pc	Por deporte	pc	05_logs/deporte_pc/ y 05_logs/tiempos_deporte_pc.csv
deportista_pc	Por deportista	pc	05_logs/deportista_pc/, 05_logs/tiempos_deportista_pc.csv y 06_evidencias/deportista_pc/

La carga por deporte se ejecutó en la máquina pc. La corrida por deporte de la máquina pb (05_logs/tiempos_deporte_pb.csv) no superó la validación de consistencia entre el CSV de tiempos y los logs: las filas de la repetición 1 de las restauraciones solo coinciden con logs rotados de ejecuciones anteriores y no con los logs actuales de esa corrida. El detalle fila por fila está en 07_documentacion/analisis/ESTADO_CSV.md.

Las rutas de este documento son relativas a la carpeta Fase 2 del repositorio. Las cifras salen de 07_documentacion/analisis/ (tablas calculadas por analizar.py a partir de los CSV de tiempos y de los logs) y de los logs de 05_logs/.

2. Descripción de la metodología

2.1 Fases del proyecto

El trabajo siguió las cuatro fases del enunciado. En la preparación se eligió la estrategia (respaldo completo más incrementales), se definieron las rutas de almacenamiento de los respaldos y se preparó un entorno común con Docker Compose. En la carga de datos se cargaron, para cada tipo de carga, la carga base y tres rondas, con un respaldo después de cada una y la medición de la fragmentación. En la restauración se eliminó la base y se restauró el respaldo completo y cada cadena de incrementales, registrando tiempos. En el análisis se compararon los resultados con tablas y gráficos.

2.2 Tipos de carga y rondas

Cada tipo de carga parte de la misma carga base (catálogos completos) y agrega tres rondas. La Tabla siguiente resume el filtro de cada ronda sobre la tabla participacion de la base de la Fase 1 (02_carga/README.md y sección 1.2 de docs/GUIA_EQUIPO_FASE2.md).

Tabla 2. Rondas de cada tipo de carga

Carga	Ronda 1	Ronda 2	Ronda 3	Filtro
Por año	París 2024	Tokio 2020	Río 2016	edición completa
Por deporte	París 2024	Tokio 2020	Río 2016	evento 1025, 100 metres, Women
Por deportista	Atenas 2004	Pekín 2008	Londres 2012	atleta 104492, Usain Bolt

La carga base deja pais 204, poblacion_pais 13026, noc 236, deporte 95, deporte_equivalencia 2 filas, y el resto de las tablas en 0 (log deportista_pc_01_carga_base.log; los logs de carga base de las otras corridas muestran los mismos valores). Los conteos acumulados después de cada ronda, tomados del log de carga de cada corrida, son los siguientes.

Tabla 3. Conteos acumulados después de cada ronda (logs de carga)

Corrida	Ronda	sede	edición	evento	atleta	particip.	resultado
anio_pa	r1_paris2024	1	1	332	11110	14892	14892
anio_pa	r2_tokio2020	2	2	546	19187	28842	28843
anio_pa	r3_rio2016	3	3	566	26625	42584	42585
deporte_pc	r1_paris2024	1	1	1	91	91	91
deporte_pc	r2_tokio2020	2	2	1	150	159	159
deporte_pc	r3_rio2016	3	3	1	206	239	239
deportista_pc	r1_atenas2004	1	1	1	1	1	1
deportista_pc	r2_pekin2008	2	2	3	1	4	4
deportista_pc	r3_londres2012	3	3	3	1	7	7

2.3 Ciclo de cada corrida

Cada corrida usa un proyecto de Docker Compose propio, con volúmenes nuevos, y sigue los pasos de la sección 1.6 de la guía del equipo. Los pasos con número par del 02 al 08 son los respaldos y del 12 al 15 las restauraciones.

Tabla 4. Pasos del ciclo

Paso	Acción
00	Instancia nueva: docker compose up, esquema (01_ddl/01_esquema.sql) y extensiones (01_ddl/02_extensiones.sql).
01	Carga base, conteo de las 11 tablas y validar.sql.
02	Respaldo FULL con pg_basebackup y verificación con pg_verifybackup.
03, 05, 07	Ronda 1, 2 y 3, con conteos y validar.sql después de cada una.
04, 06, 08	Respaldo INCR 1, 2 y 3, cada uno encadenado al anterior, y verificación.
09	Fragmentación de tablas e índices (pgstattuple), guardada en CSV.
10	DROP DATABASE olimpiadas.
11	Detener el servicio.
12 a 15	Restaurar la cadena n = 0, 1, 2 y 3 (n = número de INCR combinados), 3 repeticiones cada una, cada una desde PGDATA vacío.
16	Arrancar la base restaurada (cadena 3), comparar conteos con los del INCR 3 y medir la fragmentación otra vez.

Cada restauración (04_restauracion/restaurar.sh) vacía PGDATA, combina los respaldos (o copia el FULL si n = 0), verifica el resultado con pg_verifybackup, arranca el servidor, ejecuta validar.sql y compara con diff los conteos de las 11 tablas contra los guardados al tomar el respaldo correspondiente. Si los conteos coinciden escribe VALIDACION OK en el log.

2.4 Herramientas

Tabla 5. Herramientas y configuración

Elemento	Uso
PostgreSQL 17 (imagen postgres:17)	Motor de las instancias de la Fase 2. Versión registrada en los logs: 17.11 en pa y 17.10 en pc.
pg_basebackup -Fp -Xs -c fast	Respaldo FULL físico, en formato plano y con el WAL necesario dentro del respaldo.
pg_basebackup --incremental	Respaldo INCR encadenado al backup_manifest del respaldo anterior.
pg_combinebackup	Reconstruye un directorio de datos completo a partir del FULL y de la cadena de INCR.
pg_verifybackup	Verifica cada respaldo y cada directorio combinado contra su manifiesto.

Elemento	Uso
summarize_wal = on	Requisito de PostgreSQL 17 para tomar respaldos incrementales.
--data-checksums	Sumas de verificación de páginas, activadas al crear el clúster.
Volúmenes con nombre	pgdata y backups por proyecto de Compose: almacenamiento persistente de datos y respaldos.
Docker Compose	00_infraestructura/docker-compose.yml, el mismo para todas las corridas; un proyecto por corrida.
pgstattuple	Extensión usada para medir la fragmentación de tablas e índices.

2.5 Registro de tiempos

Los scripts de respaldo y restauración escriben cada medición en un CSV de tiempos por corrida, con el formato de la sección 4.10 de la guía: 14 columnas (persona, tipo_carga, maquina, paso, operacion, n_cadena, etapa, inicio_iso, fin_iso, segundos, bytes, validacion, repeticion, observacion). Cada corrida tiene 52 filas: 4 de respaldo (etapa basebackup) y 48 de restauración (4 cadenas por 3 repeticiones por 4 etapas: combinar, arranque, validacion y total). El archivo de cada corrida es 05_logs/tiempos_<tipo>_<persona>.csv.

La etapa total va del inicio de combinar al fin de validacion e incluye pg_verifybackup; es un agregado y no se suma con las otras etapas. De cada etapa se reporta la mediana de las 3 repeticiones. El script 07_documentacion/analisis/analizar.py valida el formato de cada CSV y cruza sus filas con los logs de la corrida antes de usarlo.

3. Modelo entidad-relación

El modelo es el de la Fase 1, alineado con el DDL que se ejecuta en cada instancia (01_ddl/01_esquema.sql). El diagrama corregido es la Figura 1, editable en draw.io. Archivos: 07_documentacion/modelo_er/Modelo_ER_fase2.png y Modelo_ER_fase2.xml.

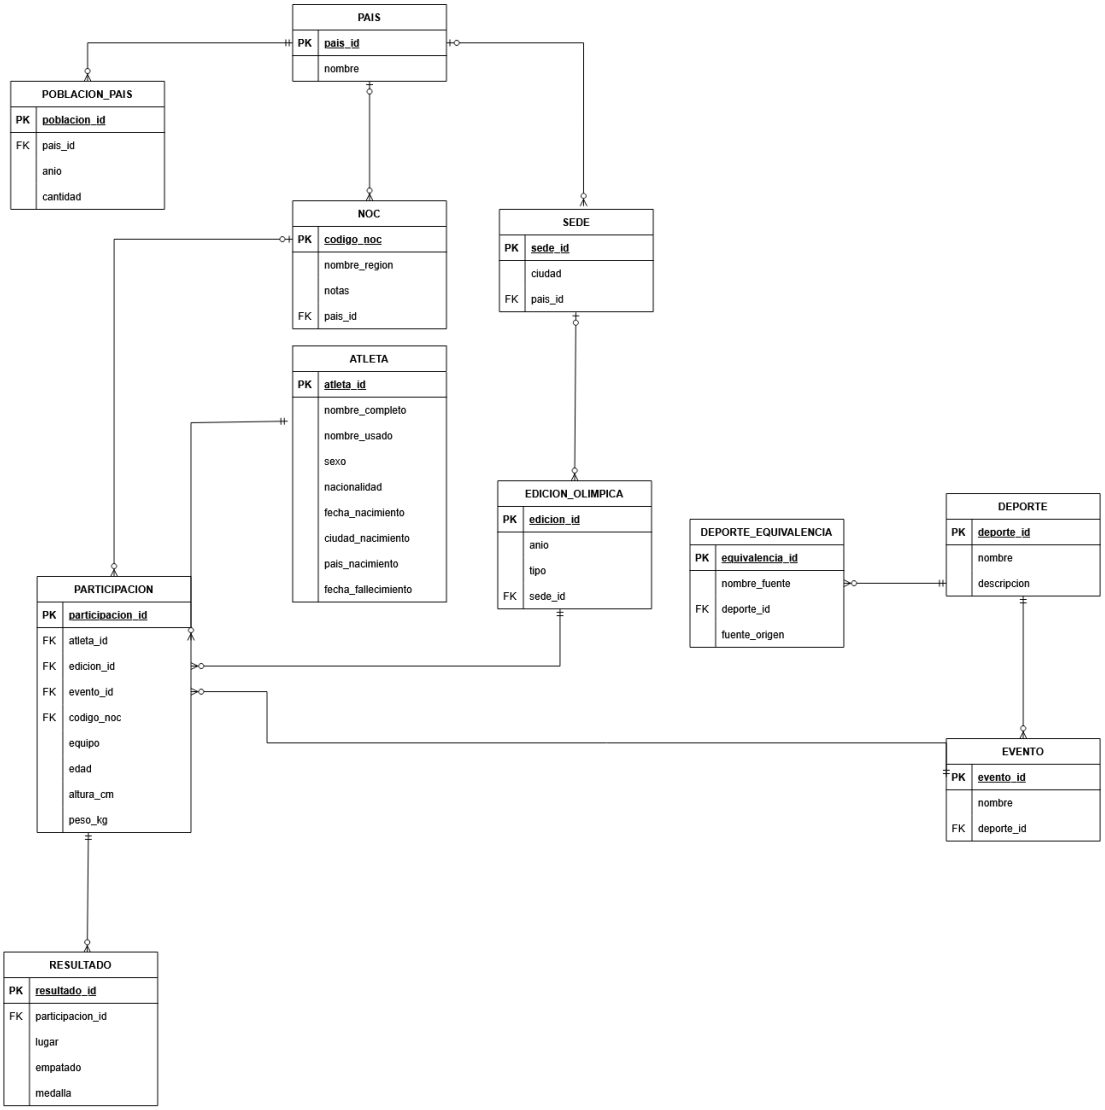


Figura 1. Modelo entidad-relación de la base olimpiadas.

3.1 Entidades y relaciones

Tabla 6. Entidades y llaves primarias

Tabla	Llave primaria	Contenido
pais	pais_id	Catálogo de países.
poblacion_pais	poblacion_id	Población de cada país por año.
noc	codigo_noc	Comités olímpicos nacionales.
sede	sede_id	Ciudad sede y su país.
edicion_olimpica	edicion_id	Edición de los juegos (año, tipo y sede).
deporte	deporte_id	Catálogo de deportes.

Tabla	Llave primaria	Contenido
deporte_equivalencia	equivalencia_id	Nombres de deporte de las fuentes y su deporte unificado.
evento	evento_id	Prueba de un deporte.
atleta	atleta_id	Datos del atleta.
participacion	participacion_id	Atleta en un evento de una edición, con su comité.
resultado	resultado_id	Lugar y medalla de una participación.

Tabla 7. Llaves foráneas y cardinalidad (padre / hijo)

Llave foránea	Padre / hijo
poblacion_pais.pais_id a pais	1 / 0..N
noc.pais_id a pais	0..1 / 0..N
sede.pais_id a pais	0..1 / 0..N
edicion_olimpica.sede_id a sede	0..1 / 0..N
deporte_equivalencia.deporte_id a deporte	1 / 0..N
evento.deporte_id a deporte	1 / 0..N
participacion.atleta_id a atleta	1 / 0..N
participacion.edicion_id a edicion_olimpica	1 / 0..N
participacion.evento_id a evento	1 / 0..N
participacion.codigo_noc a noc	0..1 / 0..N
resultado.participacion_id a participacion	1 / 0..N

Fuente: 07_documentacion/modelo_er/DISCREPANCIAS_ER_DDL.md, sección de cruce de llaves foráneas. Son 11 llaves foráneas y 11 relaciones en el diagrama.

3.2 Decisiones de diseño

PARTICIPACION a RESULTADO, 1 a N. Una participación puede tener varios resultados. En la Fase 1 el ETL deduplicó participacion por atleta, edición y evento, y conservó una fila de resultado por cada fila de la fuente 1; en las ediciones antiguas hay participaciones con varios resultados. Por eso la relación es 1 a 0..N y resultado no tiene una restricción UNIQUE sobre participacion_id.

noc.codigo_noc como llave natural. El comité usa como llave primaria su código (por ejemplo JAM): es corto, único y es el identificador con el que todas las fuentes se refieren al comité. Es la única llave natural; las demás tablas usan llaves generadas.

Llaves foráneas que admiten NULL. noc.pais_id, sede.pais_id, edicion_olimpica.sede_id y participacion.codigo_noc admiten NULL y usan ON DELETE SET NULL. En el diagrama se marcan con el extremo 0..1 del lado de la tabla padre.

atleta sin llave foránea a noc. Un atleta puede competir por distintos comités a lo largo de su carrera, así que el comité se guarda en cada participación (participacion.codigo_noc) y atleta no tiene llave foránea a noc.

3.3 Diferencias entre el diagrama original y el DDL

Se tomó el DDL como fuente de verdad y se corrigió el diagrama. La matriz completa de 16 puntos está en DISCREPANCIAS_ER_DDL.md; este es el resumen.

Tabla 8. Resumen de la matriz de diferencias

#	Elemento	Acción
1	PARTICIPACION a RESULTADO	Extremo de RESULTADO cambiado de 0..1 a 0..N.
2	NOC a ATLETA	Relación eliminada: no existe esa llave foránea.
3, 4	edicion_olimpica.anio y sede.pais_id	Marca de llave foránea quitada en anio y agregada en sede.pais_id.
5 a 9	Opcionalidad de relaciones	Extremos 0..1 en las llaves foráneas que admiten NULL; PAIS a POBLACION_PAIS como 1 a 0..N.
10, 11	Anclaje de las relaciones	Relaciones conectadas a sus tablas y a la columna de la llave foránea.
12	Tablas y atributos	Sin diferencia: 11 tablas con los mismos atributos.
13	Tipos, UNIQUE, CHECK y ON DELETE	Se documentan en DISCREPANCIAS_ER_DDL.md y en modelo_er.mmd.
14, 15	codigo_noc, nacionalidad y país de nacimiento	Se documentan como decisiones de diseño.
16	Comentario del DDL sobre PARTICIPACION y RESULTADO	Desactualizado; se documenta. No se modificó el DDL para no alterar el esquema que se respalda.

3.4 Notas sobre los datos

lugar NULL en 2024. Todas las filas de resultado de París 2024 tienen lugar NULL (14,892 filas), incluso las de medallistas: la fuente 3 solo trae la medalla (sección 1.2 de la guía). Por eso el podio se arma con la columna medalla.

Participación duplicada de Tokio 2020. Tokio 2020 tiene 13,950 participaciones y 13,951 resultados. La participación 300652 tiene dos resultados porque en la fuente 1 esa fila viene duplicada de forma idéntica, y el modelo permite 1 a N entre participación y resultado. No es un error de carga (02_carga/README.md, sección 5).

4. Plan de respaldo

4.1 Estrategia

Para cada tipo de carga se crea una instancia nueva. Después de la carga base se toma un respaldo FULL y, después de cada ronda, un respaldo incremental encadenado al anterior: INCR 1 sobre el FULL, INCR 2 sobre INCR 1 e INCR 3 sobre INCR 2. Restaurar la cadena n significa reconstruir FULL más INCR 1 a n con pg_combinebackup y arrancar el servidor sobre el resultado.

4.2 Scripts

Tabla 9. Scripts de la Fase 2

Ruta	Función
00_infraestructura/docker-compose.yml	Instancia PostgreSQL 17 con volúmenes pgdata y backups.
01_ddl/01_esquema.sql, 01_ddl/02_extensiones.sql	Esquema olimpiadas y extensiones.
02_carga/cargar_ronda.sh	Carga base y rondas en una transacción, con log por ejecución.
03_backup/backup_full.sh	Respaldo FULL, verificación y conteos de referencia.
03_backup/backup_incremental.sh	Respaldo INCR n encadenado, verificación y conteos de referencia.
03_backup/lib_tiempos.sh	Funciones comunes: filas del CSV de tiempos, logs y fila ALERTA ante errores.
04_restauracion/restaurar.sh	Restauración de la cadena n con medición de etapas.
04_restauracion/conteos.sql, validar.sql	Conteo de las 11 tablas y validación con SELECT.

Ruta	Función
04_restauracion/fragmentacion_tablas.sql, fragmentacion_indices.sql	Fragmentación con pgstattuple y pgstatindex.
07_documentacion/analisis/analizar.py	Validación de los CSV y tablas y gráficos del análisis.
07_documentacion/analisis/medir_pg_wal.sh	Tamaño de pg_wal dentro de cada respaldo.

4.3 Verificación

Cada respaldo se verifica con pg_verifybackup y guarda los conteos de las 11 tablas en /backups (conteos_full.txt y conteos_incr<n>.txt). Cada restauración verifica el directorio combinado con pg_verifybackup antes de arrancar y compara sus conteos con los del respaldo. Si un paso falla, lib_tiempos.sh escribe una fila con validacion ALERTA y el script termina con error.

4.4 Almacenamiento persistente

Los datos y los respaldos viven en volúmenes con nombre de Docker, uno de datos (pgdata) y uno de respaldos (backups) por proyecto de Compose, por ejemplo fase2_deportista_pgdata y fase2_deportista_backups. La carpeta Fase 2 se monta en /fase2 solo para leer scripts y datos y escribir logs.

4.5 Limitación de los respaldos incrementales

Un respaldo incremental de PostgreSQL no se aplica sobre un clúster en funcionamiento: pg_combinebackup reconstruye un directorio de datos completo y luego se arranca el servidor sobre él. Por eso restaurar el INCR 2 requiere FULL, INCR 1 e INCR 2, y si se pierde un respaldo de la cadena los siguientes ya no sirven (sección 1.4 de la guía del equipo).

5. Especificaciones técnicas

Configuración común del servidor, tomada de 00_infraestructura/docker-compose.yml:

Tabla 10. Configuración del servidor

Parámetro	Valor
Imagen	postgres:17
Base de datos	olimpiadas
PGDATA	/var/lib/postgresql/data/pgdata (volumen pgdata)
Respaldos	/backups (volumen backups)

Parámetro	Valor
Parámetros	summarize_wal=on, timezone y log_timezone America/Guatemala
initdb	--data-checksums
Puertos	Ninguno publicado

Tabla 11. Especificaciones de las máquinas

Elemento	Máquina pa	Máquina pc
Procesador	AMD Ryzen 7 7730U with Radeon Graphics	AMD Ryzen 7 5700U with Radeon Graphics
Núcleos / hilos	8 / 16	No registrado / 16
Memoria RAM	16097532 KB (TotalVisibleMemorySize)	14870306816 bytes (CsTotalPhysicalMemory)
Disco	P41PL NVMe SOLIDIGM 1024GB SSD, 1024209543168 bytes	WD PC SN740 SDDPMQD-512G-1101, SSD NVMe, 512110190592 bytes
Sistema operativo	Microsoft Windows 11 IoT Enterprise LTSC 10.0.26100	Microsoft Windows 11 Home 10.0.26300
Docker	No registrado	29.5.2
Recursos de Docker	CPUs=16, Mem=7981404160 bytes, kernel 6.18.33.2-microsoft-standard-WSL2	CPUs=16, Mem=7187136512 bytes, kernel 6.6.87.2-microsoft-standard-WSL2
PostgreSQL	17.11	17.10
Corridas	anio_pa	deporte_pc, deportista_pc
Fuente	Captura de las especificaciones de la máquina pa (06_evidencias/anio_pa/info_maquinaA.png); PostgreSQL de los logs de restauración	05_logs/deportista_pc/deportista_pc_00_maquina.txt y 05_logs/deporte_pc/deporte_pc_00_maquina.txt; PostgreSQL de los logs de restauración

No se incluye la máquina pb: su corrida por deporte no superó la validación de consistencia entre el CSV de tiempos y los logs.

6. Análisis detallado de resultados comparativos

Esta sección presenta solo valores medidos. Las máquinas pa y pc son distintas: entre corridas de máquinas distintas se comparan razones y tamaños en bytes, no segundos. deporte_pc y

deportista_pc se ejecutaron en la misma máquina, así que entre ellas los segundos sí son comparables. Las tres cargas son distintas y no se comparan como si fueran la misma.

6.1 Respaldos

Tabla 12. Tiempo y tamaño de cada respaldo (tabla_a_respaldos.csv)

Corrida	Respaldo	Segundos	Bytes	MB
anio_pa	FULL	1.927	49973573	49.97
anio_pa	INCR 1	1.770	27047530	27.05
anio_pa	INCR 2	1.722	29153134	29.15
anio_pa	INCR 3	1.738	29988752	29.99
deporte_pc	FULL	1.516	49973476	49.97
deporte_pc	INCR 1	0.845	21730223	21.73
deporte_pc	INCR 2	0.948	21730975	21.73
deporte_pc	INCR 3	0.921	21747383	21.75
deportista_pc	FULL	0.975	50006396	50.01
deportista_pc	INCR 1	0.920	21992494	21.99
deportista_pc	INCR 2	0.784	22033700	22.03
deportista_pc	INCR 3	0.758	21820787	21.82

Tabla 13. Razón de tamaño incr(n) / full (tabla_c2_razon_bytes.csv)

Corrida	n	Bytes INCR	Bytes FULL	Razón
anio_pa	1	27047530	49973573	0.541
anio_pa	2	29153134	49973573	0.583
anio_pa	3	29988752	49973573	0.600
deporte_pc	1	21730223	49973476	0.435
deporte_pc	2	21730975	49973476	0.435
deporte_pc	3	21747383	49973476	0.435
deportista_pc	1	21992494	50006396	0.440
deportista_pc	2	22033700	50006396	0.441
deportista_pc	3	21820787	50006396	0.436

Tabla 14. WAL dentro de cada respaldo (tabla_f_wal_respaldos.csv)

Corrida	Respaldo	Segm. WAL (log)	WAL bytes	WAL medido	% WAL	Sin WAL MB
anio_pa	FULL	1	16777216	No medido	33.6	33.20
anio_pa	INCR 1	1	16777216	No medido	62.0	10.27
anio_pa	INCR 2	1	16777216	No medido	57.5	12.38
anio_pa	INCR 3	1	16777216	No medido	55.9	13.21
deporte_pc	FULL	1	16777216	16777216	33.6	33.20
deporte_pc	INCR 1	1	16777216	16777216	77.2	4.95
deporte_pc	INCR 2	1	16777216	16777216	77.2	4.95
deporte_pc	INCR 3	1	16777216	16777216	77.1	4.97
deportista_pc	FULL	1	16777216	16777216	33.6	33.23
deportista_pc	INCR 1	1	16777216	16777216	76.3	5.22
deportista_pc	INCR 2	1	16777216	16777216	76.1	5.26
deportista_pc	INCR 3	1	16777216	16777216	76.9	5.04

La columna Segm. WAL (log) se calcula con los puntos de inicio y fin del WAL que imprime pg_basebackup en el log de cada respaldo. WAL medido es el tamaño real de pg_wal dentro del respaldo, medido con medir_pg_wal.sh sobre los volúmenes de la máquina pc; en las dos corridas de pc coincide con el cálculo desde el log. Los volúmenes de anio_pa están en la máquina pa y no se midieron.

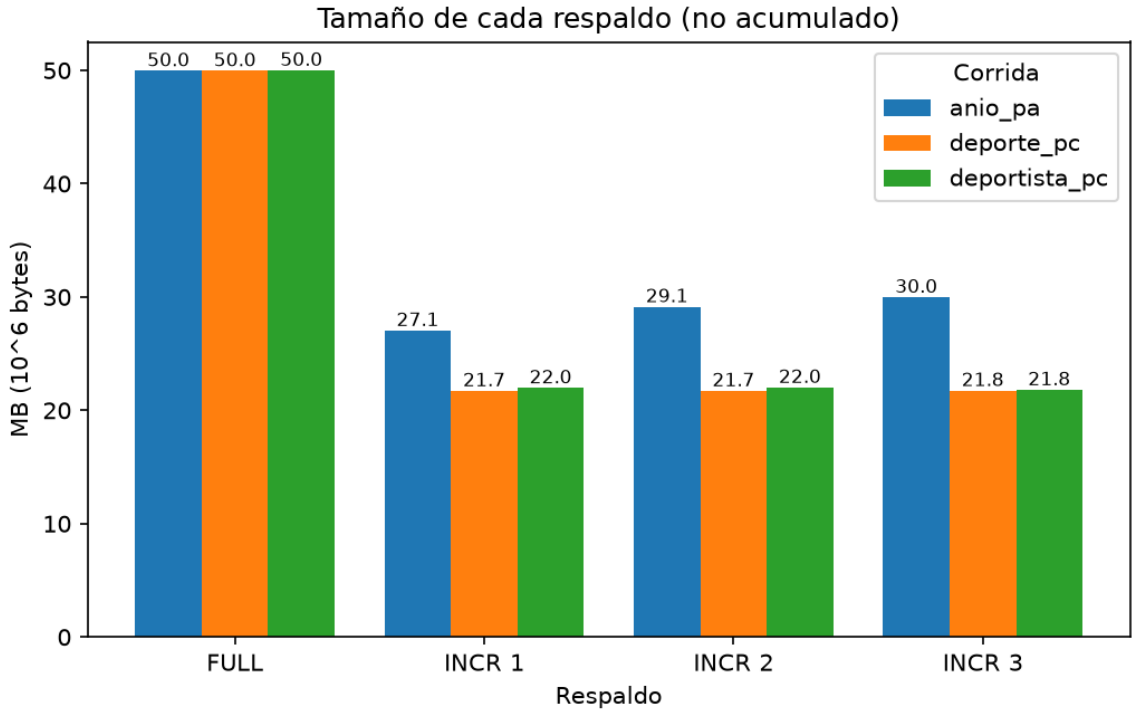


Figura 2. Tamaño de cada respaldo por corrida, en MB.

6.2 Restauración por etapa

Tabla 15. Mediana de cada etapa de la restauración, en segundos (tabla_b_restauracion_etapas.csv)

Corrida	n	Repet.	combinar	arranque	validacion
anio_pa	0	3	0.272	1.549	0.250
anio_pa	1	3	1.566	1.347	0.291
anio_pa	2	3	1.601	1.346	0.311
anio_pa	3	3	1.580	1.366	0.318
deporte_pc	0	3	0.351	0.980	0.287
deporte_pc	1	3	0.854	0.731	0.187
deporte_pc	2	3	0.937	0.639	0.193
deporte_pc	3	3	0.809	0.634	0.190
deportista_pc	0	3	0.249	0.736	0.152
deportista_pc	1	3	0.713	0.533	0.162
deportista_pc	2	3	0.753	0.532	0.157
deportista_pc	3	3	0.761	0.629	0.150

Con n = 0, restaurar.sh copia el FULL con cp -a; con n mayor o igual a 1 usa pg_combinebackup. Por eso la etapa combinar de n = 0 y la de n mayor o igual a 1 no miden la misma herramienta. La suma de las tres medianas no es igual al total, porque el total incluye pg_verifybackup y el tiempo entre etapas.

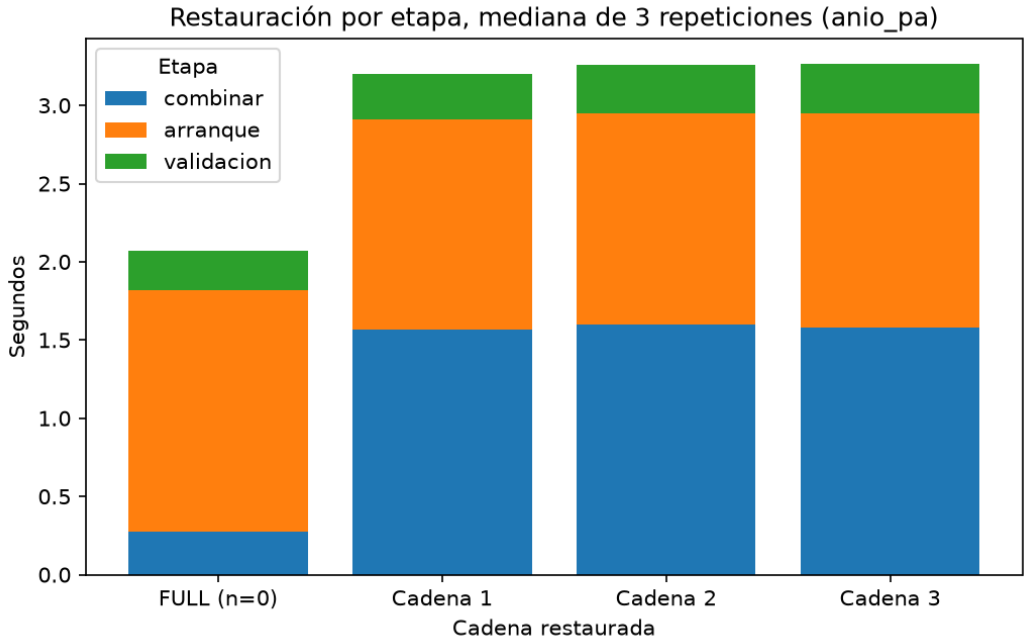


Figura 3. Restauración por etapa, mediana de 3 repeticiones, corrida anio_pa.

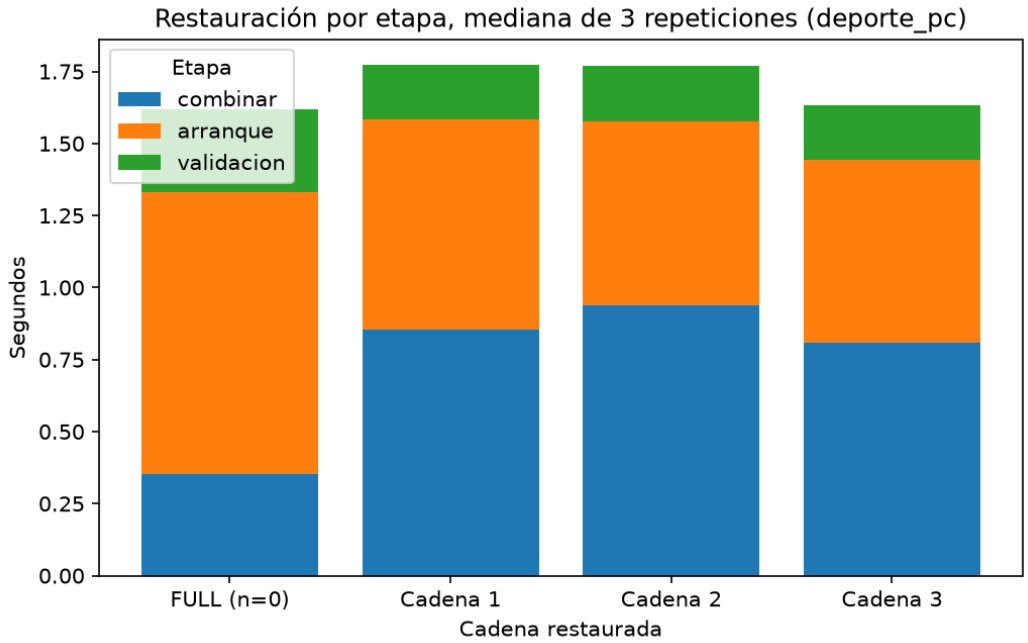


Figura 4. Restauración por etapa, mediana de 3 repeticiones, corrida deporte_pc.

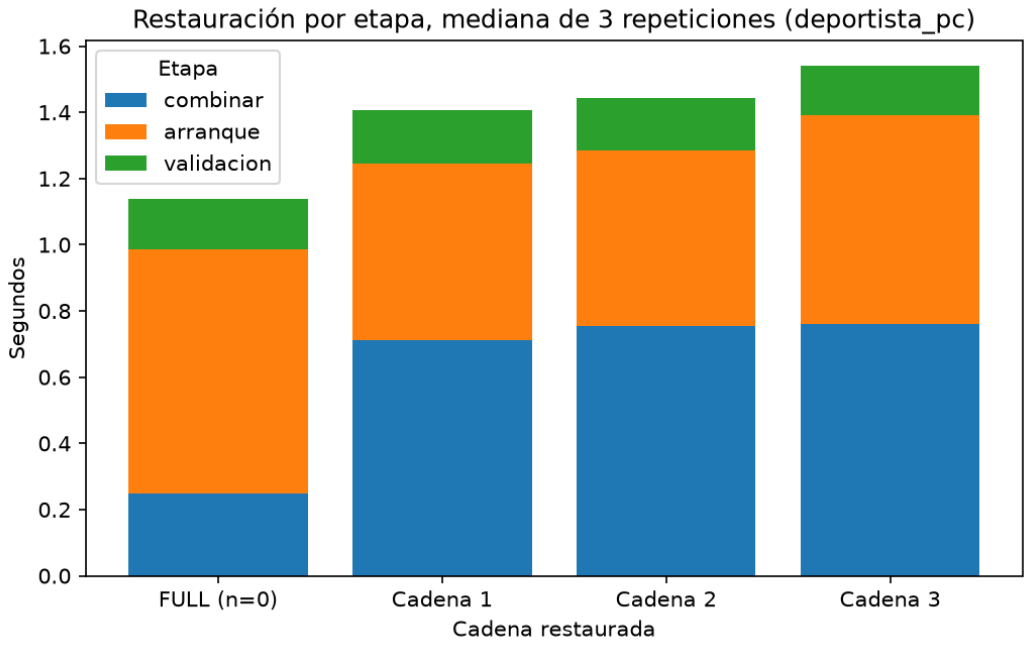


Figura 5. Restauración por etapa, mediana de 3 repeticiones, corrida deportista_pc.

6.3 Tiempo de restauración según la longitud de la cadena

Tabla 16. Tiempo total de restauración y razón restore(n) / restore(0) (tabla_c1_razon_restauracion.csv)

Corrida	n	Mediana s	Mínimo s	Máximo s	Razón
anio_pa	0	2.238	2.224	2.255	1.000
anio_pa	1	3.393	3.379	3.475	1.516
anio_pa	2	3.447	3.376	3.481	1.540
anio_pa	3	3.430	3.419	3.638	1.533
deporte_pc	0	1.837	1.580	1.926	1.000
deporte_pc	1	1.898	1.853	2.005	1.033
deporte_pc	2	1.960	1.772	1.979	1.067
deporte_pc	3	1.764	1.741	1.916	0.960
deportista_pc	0	1.267	1.256	1.409	1.000
deportista_pc	1	1.524	1.455	1.595	1.203
deportista_pc	2	1.551	1.515	1.712	1.224
deportista_pc	3	1.647	1.496	1.909	1.300

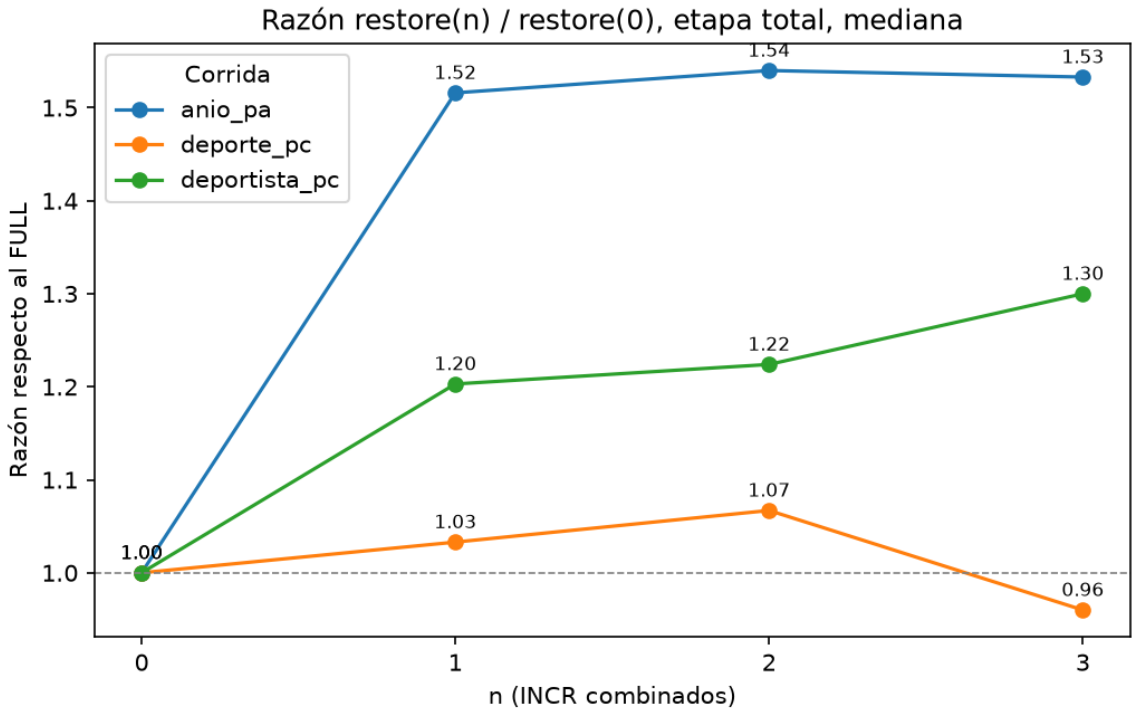


Figura 6. Razón restore(n) / restore(0) de la etapa total, mediana de 3 repeticiones.

6.4 Peso de pg_verifybackup

Tabla 17. pg_verifybackup dentro del total de restauración (tabla_e_pg_verifybackup.csv)

Corrida	n	Verify s	Total s	% del total
anio_pa	0	0.088	2.238	3.9
anio_pa	1	0.095	3.393	2.8
anio_pa	2	0.098	3.447	2.8
anio_pa	3	0.095	3.430	2.7
deporte_pc	0	0.094	1.837	5.3
deporte_pc	1	0.058	1.898	3.0
deporte_pc	2	0.065	1.960	3.3
deporte_pc	3	0.060	1.764	3.2
deportista_pc	0	0.055	1.267	4.3
deportista_pc	1	0.055	1.524	3.6
deportista_pc	2	0.055	1.551	3.5
deportista_pc	3	0.053	1.647	3.5

6.5 Fragmentación

Tabla 18. Fragmentación de las tablas con datos de las rondas, paso 09 (CSV de fragmentación de cada corrida)

Corrida	Tabla	Bytes	Filas	Filas muertas	% libre
anio_pa	atleta	2596864	26625	0	0.69
anio_pa	participacion	3186688	42584	0	0.43
anio_pa	resultado	2260992	42585	0	0.21
deporte_pc	atleta	24576	206	0	19.87
deporte_pc	participacion	24576	239	0	28.40
deporte_pc	resultado	16384	239	0	23.51
deportista_pc	atleta	8192	1	0	98.24
deportista_pc	participacion	8192	7	0	93.16
deportista_pc	resultado	8192	7	0	94.73

En las tres corridas, las 11 tablas tienen 0 filas muertas en el paso 09, y los CSV de fragmentación de tablas y de índices del paso 09 (antes de eliminar la base) y del paso 16 (después de restaurar la cadena 3) son idénticos byte a byte. La restauración física conserva las páginas tal como estaban al tomar el respaldo.

6.6 Validación de integridad

Tabla 19. Resultados de validación en los logs

Corrida	VALIDACION OK	Respaldos verificados	Restauraciones verificadas
anio_pa	12 / 12	4 / 4	12 / 12
deporte_pc	12 / 12	4 / 4	12 / 12
deportista_pc	12 / 12	4 / 4	12 / 12

En la corrida deportista_pc, las capturas de 06_evidencias/deportista_pc/ muestran cada paso; algunas de ellas:

Tabla 20. Capturas de la corrida deportista_pc

Captura	Qué muestra
deportista_pc_02_full_comando.png	Respaldo FULL y su verificación.

Captura	Qué muestra
deportista_pc_10_drop_database.png	Eliminación de la base.
deportista_pc_11_pgdata_vacio.png	PGDATA vacío al iniciar la primera restauración.
deportista_pc_15_restore_cadena3_a.png a _e.png	Restauración de la cadena completa.
deportista_pc_16_fragmentacion_post_a.png	Fragmentación después de restaurar.

En anio_pa y deporte_pc la evidencia es el log de cada paso y el CSV de tiempos.

7. Justificación de conclusiones y recomendación

7.1 Lo medido

Restaurar la cadena completa (n = 3) tomó 1.533 veces lo que el FULL en anio_pa y 1.300 veces en deportista_pc (Tabla 16). En deporte_pc la razón es 0.960, pero las 3 repeticiones de n = 0 (hasta 1.926 s) y de n = 3 (desde 1.741 s) se solapan, así que esa diferencia está dentro de la variación entre repeticiones (Tabla 16). En anio_pa y deportista_pc los rangos no se solapan.

El aumento está en la etapa combinar: en anio_pa pasa de 0.272 s con n = 0 a 1.566 a 1.601 s con n = 1 a 3, y en deportista_pc de 0.249 s a 0.713 a 0.761 s (Tabla 15).

Cada INCR pesa 0.541 a 0.600 veces el FULL en anio_pa, 0.435 en deporte_pc y 0.436 a 0.441 en deportista_pc (Tabla 13). Todos los respaldos llevan un segmento de WAL de 16777216 bytes, que es 55.9 % a 62.0 % de cada INCR en anio_pa, 77.1 % a 77.2 % en deporte_pc y 76.1 % a 76.9 % en deportista_pc (Tabla 14).

El FULL pesa 49.97 MB en anio_pa, 49.97 MB en deporte_pc y 50.01 MB en deportista_pc, y se tomó en 1.927, 1.516 y 0.975 s respectivamente (Tabla 12). pg_verifybackup pesó entre 2.7 % y 5.3 % del total de restauración (Tabla 17).

7.2 Interpretación

Sin el WAL, cada INCR pesa 10.27 a 13.21 MB en anio_pa, frente a 4.95 a 4.97 MB en deporte_pc y 5.04 a 5.26 MB en deportista_pc (Tabla 14). Los tamaños en bytes no dependen de la máquina, y la carga por año es la que agrega más filas por ronda (Tabla 3): la parte variable del INCR crece con los datos nuevos, pero con este volumen el segmento fijo de WAL sigue siendo la mayor parte del respaldo.

Donde la cadena tarda más que el FULL, la causa es la etapa combinar, que es la que crece de n = 0 a n = 1 en la Tabla 15: pg_combinebackup tiene que leer y combinar todos los respaldos de la cadena, mientras que el FULL solo se copia.

7.3 Recomendación por escenario

Con el volumen manejado (FULL de 49.97 a 50.01 MB, Tabla 12):

Si lo prioritario es el tiempo de restauración. Conviene el respaldo completo frecuente, por ejemplo uno después de cada carga. El FULL se tomó en 1.927 s como máximo (Tabla 12) y la cadena completa nunca se restauró claramente más rápido que el FULL (Tabla 16).

Si lo prioritario es el espacio o la ventana de respaldo. Conviene el incremental, porque cada INCR ocupa entre 0.435 y 0.600 veces el FULL (Tabla 13), con un FULL periódico para que la cadena sea corta: la restauración de la cadena completa llegó a 1.533 veces el FULL (Tabla 16).

En ambos casos. Por ser respaldos físicos, la restauración conserva las páginas: la fragmentación posterior fue idéntica a la previa en las tres corridas (Tabla 18), así que la elección de estrategia no cambia el estado físico de la base restaurada.

8. Alcance y limitaciones

Respaldo diferencial. El enunciado permite elegir entre incremental y diferencial; el equipo eligió incremental encadenado. El respaldo diferencial no se ejecutó ni se midió, así que no se compara con datos.

Misma carga en varias máquinas. No hay corridas de una misma carga en varias máquinas, así que no se presentan la tabla (d) ni el gráfico 4 de la sección 4.10 de la guía, que comparaban la misma carga en las tres máquinas. El enunciado no pide esa comparación.

Tamaño de pg_wal. El tamaño de pg_wal se midió en los volúmenes de las corridas de la máquina pc. En anio_pa se calcula desde el log de cada respaldo con el mismo método, que en pc coincide con la medición.

Versión de PostgreSQL. La corrida anio_pa se ejecutó con PostgreSQL 17.11 y las de la máquina pc con 17.10 (logs de restauración). Es una diferencia de versión menor de PostgreSQL 17; las comparaciones entre esas corridas ya son solo por razones porque las máquinas son distintas.

Repeticiones. Se reporta la mediana de 3 repeticiones. La caché del sistema operativo puede favorecer a las repeticiones 2 y 3.

Volumen. Las conclusiones valen para el volumen manejado (FULL de unos 50 MB) y no se extrapolan a bases más grandes.

Anexo A. Entregables

Tabla 21. Entregables y rutas

Entregable	Ruta
Documentación técnica	07_documentacion/Documentacion_Tecnica.pdf
Manual de usuario	07_documentacion/Manual_Usuario.pdf

Entregable	Ruta
Modelo entidad-relación	07_documentacion/modelo_er/
Scripts SQL de la base	01_ddl/
Scripts de carga y datos	02_carga/
Scripts de respaldo	03_backup/
Scripts de restauración y validación	04_restauracion/
Logs y CSV de tiempos	05_logs/
Capturas	06_evidencias/
Análisis comparativo	07_documentacion/analisis/ y 07_documentacion/graficos/
Infraestructura	00_infraestructura/docker-compose.yml

Anexo B. Comandos principales

Se ejecutan desde 00_infraestructura; <P> es el proyecto de Compose de la corrida, <tipo> es anio, deporte o deportista, <persona> es pa, pb o pc, y <n> es la cadena (0 a 3).

Tabla 22. Comandos principales

Acción	Comando
Levantar la instancia	docker compose -p <P> up -d --wait
Crear el esquema	docker compose -p <P> exec -u postgres db psql -v ON_ERROR_STOP=1 -d olimpiadas -f /fase2/01_ddl/01_esquema.sql
Cargar una ronda	docker compose -p <P> exec -u postgres db bash /fase2/02_carga/cargar_ronda.sh <tipo> <persona> <carpeta>
Respaldo FULL	docker compose -p <P> exec -u postgres db bash /fase2/03_backup/backup_full.sh <tipo> <persona>
Respaldo INCR n	docker compose -p <P> exec -u postgres db bash /fase2/03_backup/backup_incremental.sh <tipo> <persona> <n>
Conteos	docker compose -p <P> exec -u postgres db psql -X -At -d olimpiadas -f /fase2/04_restauracion/conteos.sql
Eliminar la base	docker compose -p <P> exec -u postgres db psql -X -d postgres -c "DROP DATABASE olimpiadas;"

Acción	Comando
Restaurar la cadena n	docker compose -p <P> stop db, y luego docker compose -p <P> run --rm --no-deps -u postgres --entrypoint bash db /fase2/04_restauracion/restaurar.sh <tipo> <persona> <n> <repetición>
Análisis	python 07_documentacion/analisis/analizar.py